




open targets / pubmed 文献

(结构)

(文档)

pmid, title, abstract, pubdate

deepseek -v4-flash :

4554 abstract

3656 abstract

提取的关联关系

chunk 已合并, 不重复API调用.

18374 triples

去重

18288 正负 triples

之前的 rule-based extract for 辅助

可行-baseline

cross-check

构建 gold dataset.

总结抽取 vs LLM

BERTopic + PubMed BERT

主题分析/补充文献

主题聚类.

deepseek LLM

实体识别 + 关系抽取

pmid + abstract

三元组 (主体-关系-客体)

Biomedical schema

实体类型/关系类型 校验

限定实体和关系

且别名统一, eg: improve 和 enhance 不同存在

LLM可构造abstract **创新!** evidence validation

证据是否真来自文献 abstract

忽略大小号、标点、空白

18288 triples

↓

16219 过滤噪声

↓

要求 similarity > 0.90 且保留 包含所有 evidence 的 token.

处理: - needed for model (prompt, 需要 evidence, 验证)

dictionary mapping

词典标准化.

解决 字符串不同, 但实际上是一个 biomedical entity.

创新4



claim-evidence

validation

